

PİMA İNDİANS DİABETES VERİ SETİ İLE MAKİNE ÖĞRENMESİ ANALİZİ

Hazırlayan: Yerkassyn Zaiymov

Öğrenci No: 21703901

1. GİRİŞ VE PROBLEM TANIMI

Bu raporun amacı, Pima Indians Diabetes veri seti kullanılarak bireylerin tıbbi özelliklerine dayalı diyabet tahmini yapmaktır. Diyabetin erken teşhisi, sağlık sektöründe kritik bir öneme sahiptir. Bu çalışmada, veri seti üzerinde keşifçi veri analizi (EDA) yapılmış, değişkenler arası lineer ilişkiler incelenmiş ve çeşitli sınıflandırma algoritmaları (Logistic Regression, KNN, SVM, Decision Tree) performans açısından karşılaştırılmıştır.

2. VERİ SETİ ÖZETİ

Veri seti Kaggle platformundan alınmış olup 768 gözlem ve 9 değişkenden oluşmaktadır.

- Bağımsız Değişkenler:** Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction, Age.
- Hedef Değişken (Target):** Outcome (0: Sağlıklı, 1: Diyabetik).

3. YÖNTEM (METHODOLOGY)

3.1. Veri Ön İşleme (Data Preprocessing)

- Eksik Veri Analizi:** Veri setinde Glucose, BMI ve BloodPressure gibi sütunlarda bulunan anlamsız "0" değerleri tespit edilmiş ve bu değerler verinin dağılımını bozmamak adına medyan değerleri ile doldurulmuştur.
- Aykırı Değer (Outlier):** Boxplot yöntemiyle aykırı değerler gözlemlenmiş ve verinin temizliği sağlanmıştır.
- Ölçeklendirme:** Mesafe temelli algoritmaların (KNN ve SVM) hatalı sonuç vermemesi için StandardScaler kullanılarak veriler normalize edilmiştir.

3.2. Modelleme

Analiz iki aşamada gerçekleştirilmiştir:

- Regresyon:** Glucose ve BMI arasındaki ilişkiyi anlamak için Basit Lineer Regresyon uygulanmıştır.
- Sınıflandırma:** Veri seti %80 eğitim, %20 test olarak ayrılmış; Logistic Regression, KNN, SVM ve Decision Tree modelleri eğitilmiştir. KNN için en iyi 'k' parametresi döngü yardımıyla belirlenmiştir.

4. BULGULAR VE ANALİZ (FINDINGS)


4.1. EDA ve Lineer İlişki Sonuçları

Ayrıca değişkenlerin dağılımları histogram ve boxplot grafikler aracılığıyla incelenmiştir.

Korelasyon matrisinde (Heatmap) en güçlü ilişkinin **Glucose** ve **Outcome** arasında olduğu görülmüştür.

- **Lineer Regresyon Sonucu:** Glikoz seviyesi ile Vücut Kitle İndeksi (BMI) arasında pozitif yönlü bir ilişki saptanmıştır. Elde edilen R2 skoru, değişkenler arasındaki ilişkinin açıklanabilirliğini göstermektedir.

4.2.





Sınıflandırma Performansı


Modellerin test verisi üzerindeki sonuçları şu şekildedir:

Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0.77	0.71	0.65	0.68
KNN (Best k)	0.75	0.68	0.61	0.64
SVM	0.76	0.70	0.63	0.66
Decision Tree	0.70	0.58	0.65	0.61


Modellerin performansı ayrıca Confusion Matrix kullanılarak değerlendirilmiştir. Bu matrisler, doğru ve yanlış sınıflandırmaların (TP, TN, FP, FN) dağılımını göstererek modellerin diyabetli bireyleri ayırt etme başarısını detaylı şekilde ortaya koymuştur.



Confusion Matrix - SVM



Confusion Matrix - Decision Tree



5. SONUÇ

Yapılan çalışmalar sonucunda, Pima Indians Diabetes veri seti üzerinde en yüksek ve dengeli başarıyı **Logistic Regression** modelinin verdiği görülmüştür (%77 Accuracy). Modelin özellikle "Recall" değerleri incelendiğinde, diyabet vakalarını tespit etme kapasitesinin kabul edilebilir düzeyde olduğu, ancak daha yüksek başarı için ileri düzey topluluk (ensemble) yöntemlerinin denenebileceği sonucuna varılmıştır.

Projenin Kaynak Kodları ve GitHub Bağlantısı:

<https://github.com/qoqosik/Pima-Indians-Diabetes>